

MiniCache KVcache层间冗余压缩

arXiv:2405.14366

1. 总览

MiniCache是一种基于层间冗余事实，通过合并相邻层的KVcache，来实现KVcache压缩的技术。



Figure 1

2. KVcache压缩领域的研究


量化: QAQ,KIVI

稀疏化:

层间压缩: minicache(本文创新点)

3. 提出背景

3.1 模型后半部分，KVcache层间相似度较大







Figure 2

横轴：层对（每两层作为一对）

纵轴：层对中两层的余弦相似度

3.2 相似的两层，也存在离群token（余弦相似度较小）



(b) Pairwise similarity in adjacent layers KV cache

Figure 3

4. MiniCache方法细节

4.1 只合并后L/2层




Figure 4

4.2 对于可合并的token进行合并




Figure 5

把k向量分解为单位方向向量和幅值（长度）：

$$k^{l-1} = e^{l-1} \cdot \mu^{l-1}$$

$$k^l = e^l \cdot \mu^l$$

通过SLERP公式 (球面线性插值) 来对方向向量进行插值:

$$e^{l-1,l} = \frac{\sin[(1-t)\Omega^{l-1,l}]}{\sin(\Omega^{l-1,l})} \cdot e^{l-1} + \frac{\sin[t\Omega^{l-1,l}]}{\sin(\Omega^{l-1,l})} \cdot e^l$$

两个向量的夹角: $\Omega^{l-1,l} = \arccos(e^{l-1} \cdot e^l)$

插入后对 e^l 的偏向程度: $t \in [0, 1]$





Figure 6

保留原始幅值:

$$\mu^{l-1}, u^l$$

4.3 对于不可合并的token，单独保存



判定不和合并token:

$$I = \{i | d_i > d_{min} + (d_{max} - d_{min}) \cdot \gamma\}$$

$$R = \{k_i | i \in I\}$$

两个token的k的角度距离，即不相似度： $d(k^l, k^{l-1}) = \frac{\Omega}{\pi}$

判定为不可合并的token的下标集合： I

单独保留:

$$I, R$$

5. 实验结果

γ 为0.05时理论压缩率:

$$ratio = \frac{4h}{3.1h + 2} \approx 1.33$$

4bit量化下的实验压缩率：（这里其实有水分，因为把量化的压缩也算上了）

Model	Method	LCC	RepoBench-P	PR-en	TREC	2wikimqa	GovReport	MQA-zh	Average	Compression Ratio
Llama-2-7B-Chat	Baseline	58.16	52.19	10.12	64.00	31.12	27.09	10.12	36.41	1x
	RTN [73]	15.44	8.76	0.79	4.00	0.30	1.93	0.07	4.90	3.21x
	SmoothQuant [70]	35.31	32.18	0.79	28.75	7.45	11.83	1.68	16.28	2.15x
	KIVI-2 [11]	49.32	43.71	4.50	63.00	24.07	24.73	10.24	31.51	3.95x
	MiniCache	58.03	52.01	9.00	64.00	30.58	25.32	10.13	35.44	5.02x
Llama-2-13B-Chat	Baseline	48.06	50.08	14.25	68.50	13.09	27.76	7.23	32.71	1x
	RTN [73]	20.89	18.62	0.33	0.00	0.52	1.68	0.16	6.03	3.21x
	SmoothQuant [70]	32.17	33.86	2.65	48.00	3.53	12.47	0.47	19.16	2.15x
	KIVI-2 [11]	48.60	48.81	13.50	68.00	14.32	25.70	7.01	32.42	3.95x
	MiniCache	48.75	48.59	13.00	68.00	14.36	26.57	7.99	32.61	5.02x
Mistral-7B	Baseline	68.06	60.46	17.71	68.00	10.87	20.09	17.10	37.33	1x
	RTN [73]	27.98	26.18	3.34	13.00	1.11	2.49	0.45	10.51	3.21x
	SmoothQuant [70]	40.63	35.14	3.40	30.50	6.03	5.00	4.12	17.55	2.15x
	KIVI-2 [11]	65.16	58.33	12.43	65.00	11.03	13.22	13.87	33.43	3.95x
	MiniCache	68.89	60.98	13.92	67.00	10.50	18.06	7.88	35.75	5.02x
Mistral-7B-Instruct	Baseline	55.51	48.96	60.00	71.00	27.33	32.85	42.74	48.32	1x
	RTN [73]	32.36	33.23	0.67	1.00	2.25	10.03	2.30	11.55	3.21x
	SmoothQuant [70]	43.84	38.63	4.79	39.50	10.34	23.61	8.33	24.43	2.15x
	KIVI-2 [11]	53.13	48.60	47.50	69.00	20.68	29.37	33.88	43.74	3.95x
	MiniCache	54.79	51.02	64.14	71.00	24.97	31.46	27.54	46.99	5.02x

Figure 8

性能：压缩一半的层，性能基本没下降





Figure 9

大批次任务下的推理速度：很快（内存读取速度是主要的性能瓶颈）



(b) BS. *vs.* Decoding Throughput

Figure 10




Figure 11

对于minicache, 只需要加载一次压缩后的KV, 就能进行两层的运算, 减少HBM读取时间。

6. 一些有趣的现象

6.1 超参数的选取

t: 合并l和l-1层时, 对l层的倾向度:




Figure 12

Normalized Frequency: 归一化后，不同相似度token的出现频率。（其实就是归一化相似度后的概率密度曲线）

这里说明，可以根据概率密度曲线，找一个最佳的 t

γ : 越大表示保留的token越多:

Table 2: Comparisons of various token retention thresholds γ by LLaMA-2-7B [5] on three benchmarks.

γ	COQA	GSM8K	TruthfulQA
0	0.603	0.108	29.813
0.01	0.620	0.126	30.226
0.02	0.630	0.143	33.903
0.05	0.647	0.152	33.213
0.1	0.643	0.152	33.903
1	0.643	0.159	33.743

Figure 13

当 γ 大于0.05后，再增大已经对性能提升帮助不大了。说明不可合并token并不多，层间的差异并不大。